

DATA SCIENCE

O Caos e o Centro

Aula 03 - Estatística Descritiva no Código

Prof. Rafael Duarte

FUNDAMENTOS

A Matemática vs A Máquina

Por que não usar só o `.mean()`?

O Python calcula a média de 10 milhões de linhas em 0.3 segundos. O problema não é o cálculo, é a interpretação. O Cientista de Dados precisa entender a fórmula para saber quando o número está mentindo.

O Papel da Estatística Descritiva

Nós não prevemos o futuro hoje (isso é Machine Learning). Hoje, nós tiramos uma fotografia do passado para tentar organizar o caos.

Média Aritmética (O Ponto de Equilíbrio)

A soma de todas as forças dividida pelo número de elementos. Puxada fortemente por valores atípicos (outliers).

- $\bar{x}$: Amostra (Lemos "xis barra").
- μ : População inteira (Lemos "Mi").
- n : Tamanho do conjunto de dados.

Símbolos Oficiais

$\bar{x}$ Σ μ

$$\bar{x} = \frac{\sum_{i=1}^n x_i}{n}$$

EXEMPLO 1 E 2 (LOUSA)

A Mentira da Média

Cenário 1: Equipe Plena

Temos 4 devs. Salários: 4k, 5k, 5k, 6k.

$$\bar{x} = \frac{4 + 5 + 5 + 6}{4} = 5k$$

Perfeito. Representa bem o grupo.

Cenário 2: O Outlier

O CEO entra na sala ganhando 100k.

$$\bar{x} = \frac{4 + 5 + 5 + 6 + 100}{5} = 24k$$

**A média diz que todos ganham R\$ 24k.
É uma mentira estatística.**

No Código: A Média

Python (Colab)

```
import pandas as pd

# Input restrito a Numéricos (int, float)
dados = [4000, 5000, 5000, 6000, 100000]

# Criando o DataFrame
df = pd.DataFrame({'salarios': dados})

# Calculando a média
media = df['salarios'].mean()

print(f"A Média é: {media}")
```

Excel

A (Salários)	
1	4000
2	5000
3	5000
4	6000
5	100000

=MÉDIA(A1:A5)

EXEMPLO 3 (LOUSA)

Média Ponderada (Com Pesos)

E quando os dados não têm a mesma importância? Usamos os Pesos (w).

Cenário: A nota de vocês na universidade. A Prova A1 vale peso 4. O Projeto A2 vale peso 6. João tirou 8.0 na A1 e 5.0 na A2.

$$\bar{x}_p = \frac{\sum (x_i \cdot w_i)}{\sum w_i}$$

$$\bar{x}_p = \frac{(8.0 \cdot 4) + (5.0 \cdot 6)}{4 + 6} = \frac{32 + 30}{10} = 6.2$$

A Salvação

Mediana e Moda

Mediana (O Meio do Caminho)

A Mediana é o valor central. Corta a sua amostra ao meio (50% para trás, 50% para frente).

REGRA DE OURO: Você é OBRIGADO a ordenar os dados primeiro (do menor para o maior). A máquina faz sozinha, no papel você tem que ordenar.

Símbolos Oficiais

Md ou $\tilde{x}$

(Lemos "Md" ou "Xis til")

EXEMPLO 1 E 2 (LOUSA)

Calculando a Mediana

Cenário Ímpar (5 itens)

Latência da API em ms: [45, 12, 50, 48, 90]

1º: Ordenar: [12, 45, 48, 50, 90]

2º: Pegar o do meio:

$$Mid = 48ms$$

Cenário Par (6 itens)

Latência: [45, 12, 50, 48, 90, 60]

1º: Ordenar: [12, 45, 48, 50, 60, 90]

2º: Média dos dois do meio:

$$\frac{48 + 50}{2} \equiv 49ms$$

No Código: A Mediana

Python (Colab)

```
import pandas as pd

# Input restrito a Numéricos (int, float)
dados = [45, 12, 50, 48, 90]

# O Pandas já ordena automaticamente!
df = pd.DataFrame({'latencia': dados})

mediana = df['latencia'].median()

print(f"Mediana: {mediana}")
```

Excel

	A (Latência)
1	45
2	12
3	50
4	48
5	90

=MED(A1:A5)

Moda (O Que Mais Repete)

É o valor mais frequente do conjunto. É a única medida de centralidade que funciona perfeitamente para variáveis categóricas (textos).

Exemplo: Log de erros do Nginx:

['404', '500', '200', '500', '500', '403'].

A Moda é o Erro 500.

Símbolo Oficial

Mo

(Lemos simplesmente "Mo")

No Código: A Moda

Python (Colab)

```
import pandas as pd

# Input aceita Numéricos e Strings (Textos)
dados = ['404', '500', '200', '500', '500']
df = pd.DataFrame({'erros': dados})

# .mode() retorna uma Serie (pode haver mais de 1 moda)
# [0] pega a primeira
moda = df['erros'].mode()[0]

print(f"Moda: {moda}")
```

Excel

	A (Erros)
1	404
2	500
3	200
4	500
5	500

```
=MOD0.ÚNICO(A1:A5)
// Antigamente: =MOD0()
```

Dispersão

Medindo o Risco e a Instabilidade

O Paradoxo da Média

Duas empresas têm salário médio de R\$ 5.000.

Empresa Alfa

[5k, 5k, 5k]

Todos iguais. Estabilidade total.

Empresa Beta

[1k, 5k, 9k]

Desigualdade total. Caos.

A média e a mediana são cegas para isso. Precisamos de uma métrica que grite quando os dados estão "espalhados".

Variância (O Motor do Caos)

Calcula a distância de cada ponto até a média. Nós elevamos ao quadrado para os números negativos não anularem os positivos.

$$s^2 = \frac{\sum (x_i - \bar{x})^2}{n - 1}$$

* Usamos (n-1) para amostras (Correção de Bessel).

Símbolos Oficiais

s^2 ou σ^2

- s^2 : Amostra
- σ^2 : População (Lemos "Sigma ao quadrado")

EXEMPLO 1 E 2 (LOUSA)

Calculando a Variância

A Estável [4, 5, 6]

Média ($\bar{x}$) = 5.

$$s^2 = \frac{(4-5)^2 + (5-5)^2 + (6-5)^2}{3-1}$$

$$s^2 = \frac{(-1)^2 + 0^2 + 1^2}{2}$$

$$s^2 = \frac{1 + 0 + 1}{2} = 1$$

A Instável [2, 5, 8]

Média ($\bar{x}$) = 5.

$$s^2 = \frac{(2-5)^2 + (5-5)^2 + (8-5)^2}{3-1}$$

$$s^2 = \frac{(-3)^2 + 0^2 + 3^2}{2}$$

$$s^2 = \frac{9 + 0 + 9}{2} = 9$$

O Herói: Desvio Padrão

A Variância "estragou" a unidade de medida ao elevar tudo ao quadrado (Ex: "Reais ao quadrado"). Para voltar ao mundo real, tiramos a Raiz Quadrada!

$$ss = \sqrt{ss^2}$$

Símbolos Oficiais

s s^2 σ

- s : Amostra
- σ : População (Lemos "Sigma")

EXEMPLO 1 E 2 (DESVIO PADRÃO)

Voltando à Realidade

A Estável

Variância deu 1.

$$ss = \sqrt{1} = 1$$

Os dados fogem da média, em geral, apenas 1 unidade.

A Instável

Variância deu 9.

$$ss = \sqrt{9} = 3$$

Os dados fogem da média, em geral, 3 unidades inteiras.

CURIOSIDADE DE NEGÓCIOS

O Padrão Ouro: Seis Sigma (6σ)

Você já deve ter ouvido falar na certificação de qualidade corporativa "Six Sigma" (Motorola, GE).

O que isso significa? Significa que o processo da empresa é TÃO perfeitamente estável que o limite de falha aceitável está a impressionantes 6 desvios padrões (6σ) de distância da média.

Resultado: 3.4 peças com defeito para cada 1 MILHÃO de peças produzidas.

O desvio padrão é o coração do controle de qualidade global.

No Código: Variância e Desvio

Python (Colab)

```
import pandas as pd

# Input restrito a Numéricos
dados = [2, 5, 8]
df = pd.DataFrame({'horas': dados})

variância = df['horas'].var()
desvio = df['horas'].std()

print(f"Var: {variância} | Std: {desvio}")
```

Excel

A (Horas)	
1	2
2	5
3	8

```
=VAR.A(A1:A3)
=DESV.PAD.A(A1:A3)
```

Dinâmica da Oficina Prática PBL

Hora de sujar as mãos no Colab e na Lousa!

- Teremos uma bateria de 6 Exercícios de Fixação. Três analíticos de "Papel/Lousa" e três puros de Python.
- Conversem, programem juntos, errem a sintaxe e corrijam.
- A Entrega: O upload do link do Colab EXCLUSIVAMENTE via Blackboard garante o +1,0 ponto na média final (NF). Só conta se entregar HOJE.



Momento da Chamada

INTERVALO

Bebam água. Na volta, abram os notebooks.

O Caos de Latência

Temos a seguinte fila de 5 requisições de rede num servidor proxy, medidas em milissegundos (ms):

[12, 15, 15, 18, 120]

- Ex 1: Calcule manualmente (com lápis e papel) a Média ($\bar{x}$), a Mediana (Md) e a Moda (Mo) deste array.
- Ex 2: Se o seu chefe de infraestrutura perguntar "Qual é o tempo de resposta *normal* da nossa API?", qual das três métricas você enviaria no relatório e por quê?

Quem é o mais confiável?

Dispersão Básica.

Dois estagiários (A e B) entregaram 3 microserviços cada. Os tempos (em horas) para finalizar cada tarefa foram:

- Estagiário A: [4, 5, 6] horas.
- Estagiário B: [2, 5, 8] horas.

A média de ambos é 5 horas. Calcule o Desvio Padrão (s) de ambos. Quem é mais previsível e por quê?

O Robô Auditor

Abram o Google Colab. É hora de fazer a máquina trabalhar.

- Ex 4: Importe o `pandas`. Crie um DataFrame com as idades de 6 usuários: [22, 25, 23, 22, 28, 26]. Crie as linhas de código que imprimam na tela a Média e a Mediana.
- Ex 5: Insira na sua lista de dados um hacker que preencheu a idade como 900 anos. Rode o código novamente e documente, com um comentário no Python (`#`), o que aconteceu com as métricas.

A Fatura da Nuvem (FinOps)

Automação de Risco

A fatura AWS dos últimos 7 dias (em dólares) foi: [150, 160, 155, 140, 150, 600, 145].

- Usando código Python, extraia o Desvio Padrão dessa semana.
- Imprima o resultado e crie um bloco de texto (Markdown) dizendo se esse cluster apresenta "baixo risco financeiro" ou "alto risco financeiro", e qual dia exato quebrou o padrão.

Terminou? Gere o Link e submeta EXCLUSIVAMENTE no Blackboard!

O Arsenal Descritivo (Resumo)

Medida	Símbolo	O que faz?	Ex: [2, 4, 4, 6]
Média	$\bar{x}$ ou μ	Ponto de equilíbrio. (Fracos contra Outliers)	4
Mediana	Md ou $\tilde{x}$	O centro exato da lista ordenada. (Imune a Outliers)	4
Moda	Mo	O valor mais repetido. (Bom para Textos)	4
Variância	s^2 ou σ^2	Média das distâncias ao quadrado.	2.66
Desv. Padrão	s ou σ	Raiz da variância. Mede o "Risco" e "Caos" real.	1.63

Cenas do Próximo Capítulo

O Raio-X Visual

Vocês já sabem descobrir quem está mentindo usando matemática. Mas ninguém entrega relatórios em matrizes de números.

- Como transformar a Mediana e o Desvio Padrão num gráfico brutalmente eficiente?
- Na semana que vem: Quartis, Boxplots e Histogramas. Faremos a máquina desenhar a verdade para o diretor.