

DATA SCIENCE

Estatística Descritiva 2

Fatiando Dados e o Raio-X Visual

Prof. Rafael Duarte

Pandas, Seaborn e Matplotlib

O QUADRO DE SOBREVIVÊNCIA

Recapitulando a Aula Passada

Métrica	O que faz?	O Ponto Fraco
Média ($\bar{x}$)	Acha o ponto de equilíbrio da base de dados.	É destruída por valores absurdos (Outliers).
Mediana (Md)	Pega o cara exatamente no meio da fila ordenada.	Ignora o peso dos valores extremos.
Variância (s^2)	Calcula a média do caos elevando tudo ao quadrado.	Unidade de medida inútil no mundo real (Ex: Reais ²).
Desv. Padrão (s)	A raiz da Variância. Mede o "risco" na unidade original.	Não nos diz de onde o caos está vindo.

O Ponto Cego dos Números

Por que Média e Desvio Padrão não bastam?

Imagine duas equipes de vendas. Ambas têm média salarial de R\$5.000 e desvio padrão de R\$1.000.

- Equipe A: Todo mundo ganha muito perto de 5.000.
- Equipe B: Metade ganha 4.000 e a outra metade ganha 6.000. Ninguém ganha 5.000.

O Diagnóstico

Os números absolutos nos cegam para a Geometria dos Dados. Precisamos de ferramentas matemáticas para fatiar essa amostra e enxergar a distribuição exata.

Fatiando a Pizza

Quartis, Limites e as Cercas Matemáticas

O Conceito de Quartil

Se a Mediana corta a base de dados em duas metades (50%), os Quartis cortam a base em quatro fatias exatas de 25%.

Min |--- 25% ---| Q_1 |--- 25% ---| Q_2 |--- 25% ---| Q_3 |--- 25% ---|
Max

- Q_1 (Primeiro Quartil): A fronteira dos 25% menores valores.
- Q_2 (Segundo Quartil): A Mediana exata (50%).
- Q_3 (Terceiro Quartil): A fronteira onde começam os 25% maiores valores (a "elite").

Aviso: A base DEVE estar ordenada do menor para o maior antes de qualquer corte.

EXEMPLO 1: ENUNCIADO

Cálculo Manual de Quartis

O Problema da API

O seu time de monitoramento capturou 7 tempos de resposta (em milissegundos) de uma API no servidor. Os tempos registrados foram:

[45, 12, 60, 20, 30, 15, 80]

Missão: Calcule os valores exatos de Q_1 , Q_2 (Mediana) e Q_3 para este conjunto.

EXEMPLO 1: RESOLUÇÃO

Calculando Passo a Passo

Passo 1: Ordenar obrigatoriamente!

12, 15, 20, 30, 45, 60, 80

Passo 2: Achar o Q_2 (Mediana). Temos 7 elementos (Ímpar). Cortamos 3 de cada lado.

12, 15, 20, [30], 45, 60, 80 $\Rightarrow Q_2 = 30$

Passo 3: Achar o Q_1 (A mediana da metade inferior).

12, [15], 20 $\Rightarrow Q_1 = 15$

Passo 4: Achar o Q_3 (A mediana da metade superior).

45, [60], 80 $\Rightarrow Q_3 = 60$

O Intervalo Interquartil (IQR)

Se os dados extremos (outliers) mentem para nós, o que acontece se ignorarmos as pontas e olharmos apenas para o "miolo" da sociedade?

$$IQR = Q_3 - Q_1$$

O IQR (Intervalo Interquartil) representa a distância onde estão agrupados os 50% mais normais e comportados da sua base de dados. Ele é o coração da nossa estatística a partir de agora.

EXEMPLO 2: ENUNCIADO

Descobrimos o Miolo (IQR)

O Problema do Cloud Billing

Vocês são engenheiros de dados analisando as faturas mensais (em dólares) de servidores de centenas de clientes de um SaaS. A equipe de análise informou que:

- O 1º Quartil (Q_1) das faturas é de \$150.
- O 3º Quartil (Q_3) das faturas é de \$250.

Missão: Calcule o IQR e explique o que esse número significa para a diretoria.

EXEMPLO 2: RESOLUÇÃO

Aplicando a Fórmula do IQR

O Cálculo:

$$IQR = Q_3 - Q_1$$
$$IQR = 250 - 150 = 100$$

O Significado Executivo:

"Diretor, o valor de 100 dólares é a variação que engloba o núcleo central da nossa base. Ou seja, 50% dos nossos clientes mais 'comportados' têm faturas que variam no máximo 100 dólares entre si (de 150 a 250). Quem paga acima disso já começa a virar elite."

As Cercas Matemáticas (Limites)

Como uma Inteligência Artificial sabe o que é uma fraude e o que não é? Ela não "chuta". Ela cria cercas matemáticas ao redor do IQR.

Qualquer dado que cair FORA dessas duas cercas é marcado automaticamente pelo algoritmo como um Outlier (Anomalia).

As Fórmulas Universais

Cerca Inferior (Mínimo Aceitável):

$$LI = Q_1 - 1.5 \times IQR$$

Cerca Superior (Máximo Aceitável):

$$LS = Q_3 + 1.5 \times IQR$$

EXEMPLO 3: ENUNCIADO

As Cercas da Fraude

Automação de Alertas

Aproveitando a base de faturas do Exemplo 2, onde já sabemos que:

- $Q_1 = 150$
- $Q_3 = 250$
- $IQR = 100$

Missão: Calcule os Limites Inferior e Superior aceitáveis. A partir de qual valor de fatura o nosso sistema deve bloquear o cartão do cliente por suspeita de fraude/roubo de credencial?

EXEMPLO 3: RESOLUÇÃO

Construindo os Limites

1. Calculando a tolerância ($1.5 \times IQR$):

$$1.5 \times 100 = 150$$

2. Cerca Inferior (LI):

$$LI = 150 - 150 = 0$$

3. Cerca Superior (LS):

$$LS = 250 + 150 = 400$$

Conclusão: Qualquer fatura acima de 400 Dólares será congelada pelo sistema anti-fraude. É matematicamente irreal para o comportamento desse grupo.

EXEMPLO 4: ENUNCIADO

O Efeito Blindagem do IQR

O CEO Invasor

Temos uma base de dados com 1000 salários de estagiários, variando de 1000 a 2000 reais. O Desvio Padrão é de R 200, *eo IQR é de R* 400.

De repente, um erro no banco de dados insere o salário do CEO (1 Milhão de reais) na mesma tabela.

Missão: Responda sem fazer cálculos: O que vai acontecer com a Média, o Desvio Padrão e o IQR?

EXEMPLO 4: RESOLUÇÃO

Por que amamos os Quartis

A Média e o Desvio Padrão: Vão ser destruídos. A média saltará absurdamente para a direita e o desvio padrão vai gritar que a equipe tem um "risco" de variação gigantesco.

O IQR (A Mágica): Vai permanecer intacto (ou quase inalterado).

Por quê? Porque o CEO de 1 milhão entrou no final da fila (nos 25% extremos). O IQR ($Q_3 - Q_1$) avalia APENAS os 50% centrais da base. Ele corta os extremos fora antes de calcular. Ele é estatisticamente cego para anomalias.

EXEMPLO 5: ENUNCIADO

A Máquina faz o Trabalho Sujo

O Arsenal do Python (Pandas)

Vocês não vão calcular fórmulas de limites na mão na vida real. A biblioteca Pandas do Python tem um comando que cospe absolutamente todas as métricas descritivas de uma tabela em uma fração de segundo.

Missão: Como acionar esse raio-x estatístico via código?

EXEMPLO 5: RESOLUÇÃO

O Comando `.describe()`

Uma linha de código resolve o semestre inteiro:

```
import pandas as pd

# df é o nosso DataFrame (tabela)
resumo = df['salarios'].describe()
print(resumo)
```

count	1000.0
mean	1500.0
std	200.0
25% (Q_1)	1300.0
50% (Q_2)	1500.0
75% (Q_3)	1700.0
max	1000000.0

O Raio-X Visual

Boxplots, Histogramas e a biblioteca Seaborn.

O Boxplot (Gráfico de Caixa)

O Boxplot é o desenho exato das Cercas e Quartis que acabamos de calcular. Ele plota 5 elementos vitais:

- A "Caixa" central é o IQR (vai do Q_1 ao Q_3). 50% dos dados moram nela.
- A linha que corta a caixa no meio é a Mediana (Q_2).
- Os "Bigodes" (linhas saindo da caixa) vão até as Cercas Superior e Inferior.
- **Qualquer bolinha desenhada FORA dos bigodes é um OUTLIER matemático.**

EXEMPLO 6: ENUNCIADO

Interpretando a Caixa

O Analista de Marketing

Vocês receberam o Boxplot da idade dos clientes da sua plataforma.

- A linha inferior da caixa (Q_1) bate no número 20.
- A linha superior da caixa (Q_3) bate no número 40.
- A ponta do bigode superior bate no número 70.
- Existem 3 bolinhas marcadas nos números 82, 85 e 90.

Missão: Traduzam esse gráfico. A partir de que idade o cliente vira uma anomalia para a equipe de Marketing?

EXEMPLO 6: RESOLUÇÃO

Lendo o Gráfico sem Matemática

A leitura de um Boxplot é imediata:

- O Miolo: Metade dos nossos clientes tem entre 20 e 40 anos (o tamanho da caixa). Esse é o nosso público-alvo principal.
- O Limite Normal: O cliente mais velho considerado "normal" pelo sistema tem 70 anos (a ponta extrema do bigode).
- **A Anomalia: Qualquer cliente com 71 anos ou mais é uma aberração matemática para este grupo. As três bolinhas (82, 85 e 90) são casos totalmente isolados que não devem guiar as campanhas principais da empresa.**

EXEMPLO 7: ENUNCIADO

Desenhando no Python

O Poder do Seaborn

No Python, não usamos gráficos nativos secos. Usamos a biblioteca de visualização estatística chamada Seaborn. Ela gera o Boxplot com cercas perfeitas automaticamente.

Missão: Como desenhar um boxplot com duas linhas de código?

EXEMPLO 7: RESOLUÇÃO

Sintaxe do Boxplot

```
import seaborn as sns
import matplotlib.pyplot as plt

# A mágica acontece aqui:
# Data é a tabela, x é a coluna que queremos ver
sns.boxplot(data=df, x='idade')

# Mostra a imagem na tela
plt.show()
```

Só isso. A biblioteca faz as subtrações e pinta os outliers pra você.

Histogramas e a Regra de Sturges

O Boxplot é ótimo para limites, mas o Histograma é quem mostra o formato da montanha.

Ele divide milhares de dados em pequenos "baldes" (bins) de valores. Mas, se deixarmos o Python escolher a quantidade de baldes sozinho, ele pode gerar um gráfico "sujo" demais ou "amassado" demais.

A Regra de Ouro (Sturges)

A fórmula que define matematicamente quantos baldes (K) o seu gráfico deve ter baseando-se no tamanho da sua amostra (N).

$$k = 1 + 3.322 \times \log_{10}(N)$$

EXEMPLO 8: ENUNCIADO

Calculando a Regra de Sturges

Montando os Baldes

Você extraiu um log contendo exatamente 1.000 transações financeiras ($N = 1000$) e precisa plotar o Histograma.

Missão: Usando a Regra de Sturges, em quantos "baldes" (colunas) esse gráfico deve ser dividido para ficar esteticamente e estatisticamente perfeito?

EXEMPLO 8: RESOLUÇÃO

A Matemática Logarítmica

1. Achar o $\log_{10}$ de N:

O logaritmo na base 10 de 1000 é 3 (pois $10^3 = 1000$).

2. Aplicar na fórmula de Sturges:

$$k = 1 + 3.322 \times 3$$

$$k = 1 + 9.966 = \mathbf{10.966}$$

Conclusão: Como não existe "meio balde", nós arredondamos. O seu gráfico deverá ser configurado para ter 11 colunas ($bins = 11$).

EXEMPLO 9: ENUNCIADO

A Assimetria do Histograma

A Cauda Longa

Ao desenhar o histograma das idades dos bilionários de um país, você nota que a montanha de dados sobe muito rápido nos 40 anos, desce, e cria uma "cauda longa" que se estende suavemente para a direita até os 90 anos.

Missão: O que essa assimetria à direita nos diz sobre a briga entre a Média e a Mediana? Qual delas é maior?

EXEMPLO 9: RESOLUÇÃO

A Média Puxada

Sempre que a cauda do Histograma for longa para a Direita, significa que existem valores extremos e isolados do lado direito (os bilionários muito velhos).

- A Mediana fica ancorada perto do topo da montanha (onde está o maior volume de pessoas de 40 anos).
- **A Média é puxada pela cauda. Como ela é sensível aos extremos, ela vai derrapar para a direita em direção aos idosos.**

Veredito: Numa Assimetria à Direita, a Média é maior que a Mediana.

EXEMPLO 10: ENUNCIADO

Plotando Histograma com Python

O Desenho Final

Vocês calcularam a regra de Sturges (11 baldes) no Exemplo 8. Agora, precisam falar para o Python gerar o Histograma com essa configuração exata.

Missão: Qual o código no Seaborn para traçar o Histograma forçando a quantidade de Bins calculada?

EXEMPLO 10: RESOLUÇÃO

Sintaxe do Histogram

```
import seaborn as sns
import matplotlib.pyplot as plt

# A propriedade "bins" trava a regra de Sturges
sns.histplot(data=df, x='transacoes', bins=11)

# Mostra a imagem na tela
plt.show()
```

Dinâmica da Oficina Prática PBL

Google Colab & Lousa Digital

- Teremos uma bateria de 6 Desafios.
- Os dois primeiros são matemáticos. Os últimos exigem código Python no Colab.
- A Entrega: O upload do link do Colab via Blackboard até o final da aula (ou como tarefa extraclasse) garante o bônus de engajamento na média final (NF).



Momento da Chamada

INTERVALO

Bebam café. Na volta abram o Google Colab.

OFICINA PBL: DESAFIO 1

Encontrando o Centro (Lousa)

Dado o array desordenado contendo a pontuação de 7 jogadores:

[14, 10, 8, 22, 19, 11, 20]

Missão: Calcule a lápis qual é a Mediana (Q_2) deste conjunto.

RESOLUÇÃO: DESAFIO 1

Gabarito: O Centro

1. Ordenar (Obrigatório!):

8, 10, 11, 14, 19, 20, 22

2. Índice do Q_2 :

Temos 7 números. O centro exato corta 3 pra cada lado.

Mediana (Q_2) = 14

A Cerca do Servidor (Lousa)

O tempo de CPU de um servidor cloud foi medido durante a noite. Vocês descobriram que:

- $Q_1 = 40$ (milissegundos)
- $Q_3 = 60$ (milissegundos)

Missão: Calcule a Cerca Superior matemática. O sistema registrou um pico isolado de 95ms de processamento. Esse pico deve ser considerado um Outlier?

RESOLUÇÃO: DESAFIO 2

Gabarito: Limite Superior

1. Calcular IQR:

$$60 - 40 = 20$$

2. Fórmula do Limite Superior ($Q_3 + 1.5 \times IQR$):

$$60 + 1.5 \times 20 = 60 + 30 = \mathbf{90}$$

Conclusão: Sim, é Outlier. O Limite estatístico era 90ms. Qualquer coisa acima disso (como o pico de 95) é uma anomalia para este servidor.

OFICINA PBL: DESAFIO 3

Sturges Automatizado (Colab)

Abram o Python! Temos um dataset contendo exatos 8.500 registros de fraude.

Missão: Usando a biblioteca matemática nativa do Python, escreva a fórmula de Sturges ($k = 1 + 3.322 \times \log_{10} N$) e imprima quantos Bins devemos usar neste gráfico.

RESOLUÇÃO: DESAFIO 3

Gabarito: Código Python

```
import math

n = 8500
k = 1 + (3.322 * math.log10(n))

# Imprimindo o resultado
print(f"Número de Bins ideal: {k}")
# Resultado esperado: ~14.05 (14 bins)
```

OFICINA PBL: DESAFIO 4

Importação e Análise (Colab)

Vamos criar dados na força bruta.

1. Importem o Pandas.
2. Criem uma coluna 'idade' com os valores: ``[22, 25, 23, 30, 24, 80]``.
3. Coloquem isso em um ``pd.DataFrame()``.
4. Rodem o comando de raio-x estatístico do Pandas.

Missão: Identifique no Output qual é o valor gerado para o Q_3 das idades.

RESOLUÇÃO: DESAFIO 4

Gabarito: .describe()

```
import pandas as pd

# Criando os dados
df = pd.DataFrame({'idade': [22, 25, 23, 30, 24, 80]})

# Raio-X
resumo = df['idade'].describe()
print(resumo)
```

Resposta: Olhando a linha "75%" no console, o Python cravou o Q_3 em 28.75 anos.

OFICINA PBL: DESAFIO 5

Desenhando a Caixa (Colab)

O DataFrame do desafio anterior tem uma clara anomalia (um cliente de 80 anos).

Missão: Importem a biblioteca `seaborn` e `matplotlib` e desenhem um Boxplot do DataFrame criado acima para escancorar esse idoso graficamente.

RESOLUÇÃO: DESAFIO 5

Gabarito: Gráfico Seaborn

```
import seaborn as sns
import matplotlib.pyplot as plt

# Apenas passar o DF e a coluna
sns.boxplot(data=df, x='idade')

# Renderiza a imagem
plt.show()
```

A bolinha no 80 vai pular para fora do bigode superior no gráfico de vocês.

A Cirurgia (Remoção de Outliers)

Saber enxergar anomalias é fácil. Extirpá-las da base exige código. No DataFrame de idades `[22, 25, 23, 30, 24, 80]`, vamos supor que vocês calcularam matematicamente que o Limite Superior da Cerca é 38 anos.

Missão Final: Escrevam o código Pandas que cria um "DataFrame Limpo", filtrando a base original para manter APENAS clientes com idade menor ou igual a 38.

RESOLUÇÃO: DESAFIO 6

Gabarito: Filtro Lógico no Pandas

```
# Define o teto matemático (Upper Fence)
limite_superior = 38

# Joga a condição lógica dentro dos colchetes do DF
# Ele devolve a base purificada!
df_limpo = df[ df['idade'] <= limite_superior ]

print(df_limpo)
```

A linha contendo o 80 foi brutalmente deletada.

Resumo da Ópera

- **A Visualização não perdoa:** Se a Média maquia os dados escondendo o caos, os Quartis e o Boxplot expõem exatamente onde a "normalidade" acaba.
- **Matemática vs Algoritmo:** O $1.5 \times IQR$ é a lei universal para detectar fraude sem achismos.
- **Python te liberta:** Ninguém desenha bigodes em planilhas. Uma chamada de ``.describe()`` e um ``.boxplot()`` fazem o que um humano levaria dias em uma base de milhões de linhas.

Cenas do Próximo Capítulo

A Prova de Fogo (Testes de Hipótese)

Até agora estivemos apenas explorando o formato e as mentiras do passado.

- Na próxima aula, vamos saltar para a Inferência Estatística.
- O Teste A/B: Vamos provar matematicamente se a interface Nova do site realmente vende mais que a Antiga, usando o P-Valor[cite: 2].