

DATA SCIENCE

Inferência Estatística

Aula 05 - Categorias, Séries Temporais e o Teste A/B

Prof. Rafael Duarte

O Mapa Visual do Cientista de Dados

Na aula passada, usamos Boxplots e Histogramas. Eles são ferramentas exclusivas para variáveis contínuas (dinheiro, peso, idade). Mas como plotamos texto e categorias?

1. Frequência Pura

"Quantos clientes acessaram via Mobile vs Desktop?"

Ferramenta: Gráfico de Contagem (Countplot).

2. Categoria x Número

"Qual o faturamento médio de quem usa Mobile vs Desktop?"

Ferramenta: Gráfico de Barras (Barplot).

3. O Fator Tempo

"Como esse faturamento oscilou nos últimos 30 dias?"

Ferramenta: Gráfico de Linhas (Lineplot).

Proporções e Contagem (Countplot)

O countplot do Seaborn apenas conta quantas vezes uma categoria de texto aparece na base de dados (Ex: Contar ocorrências de "Mobile"). Esqueça gráficos de Pizza, eles distorcem a percepção humana de área.

```
import seaborn as sns
import matplotlib.pyplot as plt

# Eixo X recebe a coluna de categorias
sns.countplot(
    data=df,
    x='dispositivo'
)
plt.show()
```

Leitura Visual

Altura da barra = Volume Absoluto. Simples e letal. Útil para descobrir se a sua base de dados está desbalanceada antes de treinar uma IA.

Cruzando Variáveis (Barplot)

O barplot calcula a MÉDIA de um número agrupado por uma categoria de texto.

```
# Eixo X = Categoria | Eixo Y = Número
sns.barplot(
    data=df,
    x='regiao',
    y='faturamento'
)
plt.show()
```

A Antena de Erro (Haste Preta)

O Seaborn desenha um "fio" preto no topo da barra. É o Intervalo de Confiança. Se a haste for gigantesca, significa que os faturamentos daquela região oscilam loucamente (alta variância). Não confie naquela média.

A Evolução do Caos (Lineplot)

Sempre que uma das variáveis for uma Data (Time Series), nós abandonamos as barras. Linhas conectadas revelam sazonalidade e tendências.

```
# Eixo X DEVE ser temporal
sns.lineplot(
    data=df,
    x='data_compra',
    y='faturamento'
)
plt.show()
```

Identificando Anomalias

Um pico agudo e repentino no gráfico de linhas é o alerta visual de que a sua empresa sofreu um ataque, uma fraude ou uma campanha de marketing viralizou.

A TRANSIÇÃO METODOLÓGICA

Estatística Descritiva vs Inferência

Estatística Descritiva (O Passado)

É a matemática de olhar pelo retrovisor. Nós desenhamos gráficos (Barplot) e tiramos a média de vendas de ontem. O problema? Saber o que ocorreu ontem não prova que o padrão se repetirá amanhã.

Inferência Estatística (O Futuro)

É a capacidade matemática de olhar para uma amostra pequena e cravar, com margem de segurança calculada, que aquele exato comportamento se estenderá para a população do mundo inteiro.

O Viés da Sorte (O Cenário Executivo)

O Problema de Negócio: Teste A/B

A equipe de UI/UX alterou a cor do botão de checkout de Verde (Versão A) para Laranja (Versão B). Monitoramos as primeiras 500 compras. Ao desenhar o Barplot, o resultado foi esse:

- Ticket Médio Versão A (Verde): R\$ 120,00
- Ticket Médio Versão B (Laranja): R\$ 132,00

A Pergunta de 1 Milhão de Reais:

A cor laranja realmente faz as pessoas gastarem mais? Ou nós apenas demos sorte de que, naquelas horas específicas, uma leva de clientes endinheirados calhou de cair na Versão B e distorceu a nossa média no gráfico?

O Tribunal da Ciência

A Ciência de Dados opera sob a presunção de inocência. Até que a matemática prove o contrário, o botão Laranja não serve para absolutamente nada. Chamamos isso de formulação de Hipóteses.

Hipótese Nula (H_0)

O Status Quo (O Acaso)

Afirma que o botão Laranja NÃO teve impacto. O ganho de R\$ 12,00 no gráfico foi puro ruído estatístico, mera obra do acaso.

Hipótese Alternativa (H_1)

A Descoberta

Afirma que a diferença é real. As populações são matematicamente distintas e a mudança da tela causou um aumento sistemático no ticket.

SEM DECOREBA DE FÓRMULA

Sinal vs. Ruído

Como a matemática do "Teste T" descobre se os R\$ 12,00 foram pura sorte? Ela avalia a guerra entre Sinal e Ruído na amostra.

- **O Sinal:** É a diferença bruta. Quanto maior a diferença financeira entre as médias de A e B, mais forte é o indício de que a tela funciona.
- **O Ruído (Dispersão):** É a bagunça dos dados. Se na Versão B nós tivemos vendas variando descontroladamente (compras de R\$ 3.000), a média de R\$ 132 é muito fraca, muito incerta. O ruído esmaga o sinal.

Conclusão: O algoritmo pune duramente dados que variam demais.

O Que Diabos é o P-Valor?

O resultado de qualquer Teste de Hipótese na máquina gera o "P-Valor" (Probability Value). Ele NÃO é a chance do botão estar certo. É o índice do seu fracasso.

A Tradução Executiva:

"Se a Hipótese Nula (H_0) for absoluta verdade na vida real, qual é a probabilidade estatística de eu ter observado essa diferença ilusória de R\$ 12,00 unicamente por causa de um tremendo golpe de sorte na amostra?"

- Se o P-Valor for gigantesco (ex: 40%): A chance de ter sido só sorte é absurda. Não publique essa alteração no site.
- Se o P-Valor for microscópico (ex: 1%): A chance de ser sorte beira a impossibilidade. O efeito visual na tela causou impacto real no cérebro do consumidor.

A Matriz de Decisão (α)

Nós precisamos de uma régua para definir o que é um risco "baixo o suficiente". O limite de erro universal na Engenharia e na Ciência de Dados é o Nível de Significância (α).

Regra de Corte: $\alpha = 0.05$ (5%)

Se o Computador retornar:	Ação Estatística	Decisão da Diretoria
$p < 0.05$	Rejeitamos a Nula (H_0). Aceitamos H_1 .	Ganho validado. O time recebe o bônus.
$p \geq 0.05$	Fracasso em rejeitar a Nula (H_0).	Tudo foi sorte. Descartem a nova interface.

A AUTOMAÇÃO

O Juiz Computacional: SciPy

Nós não calculamos variância agrupada ou estatística-t à mão. A biblioteca scipy é o padrão-ouro de computação científica no Python. O módulo stats possui algoritmos para qualquer Teste de Hipótese possível.

ttest_ind

Teste T para Amostras Independentes. É o modelo matemático usado quando queremos comparar se as médias de dois grupos diferentes (Grupo A vs Grupo B) são estatisticamente iguais ou não.

Exemplo de Arquitetura

A função exige dois parâmetros de entrada (as arrays com os valores isolados) e retorna uma tupla com dois valores de saída. Nós isolamos apenas o p_valor.

```
from scipy import stats

# 1. Invocando o Juiz (A máquina faz o cálculo interno)
t_stat, p_valor = stats.ttest_ind(
    array_faturamento_A,
    array_faturamento_B
)

# 2. Imprimindo formatado com 4 casas decimais
print(f"O P-Valor calculado foi: {p_valor:.4f}")
```

Desenvolvimento Assistido

Na engenharia de dados, não queremos ficar lendo P-Valor com o olho na tela toda vez que o painel atualizar. Nós engavetamos o resultado em um condicional if / else para o robô imprimir a decisão gerencial sozinho.

```
# A Regra dos 5% de Alfa
if p_valor < 0.05:
    print("Sucesso! A diferença é estatisticamente real (H1).")
    print("Ação: Fazer deploy da Versão B para 100% da base.")
else:
    print("Fracasso! É puro ruído e sorte (H0).")
    print("Ação: Manter o design da Versão A e cancelar bônus.")
```

INTERVALO

Acessem o Google Colab. A Oficina PBL e o código real vão começar.

O Julgamento do E-Commerce

Vocês simularão o papel do Arquiteto de Dados validando o deploy de produção de um e-commerce gigante que acabou de rodar um Teste A/B.

As 3 Missões no Jupyter Notebook:

1. Modelagem: Importar o Pandas e gerar as arrays sintéticas de ticket médio usando `np.random`. Unificar tudo em um único DataFrame contendo a "Versão" (A ou B) e o "Ticket".
2. A Prova Visual: Importar o Seaborn e plotar o barplot para confirmar visualmente se uma das barras parece maior que a outra.
3. O Veredito Computacional: Isolar (filtrar) o ticket A e o ticket B, jogá-los no motor de moer carne do `scipy.stats`, extrair o P-Valor e codificar a resposta de negócios baseada no corte de 5%.

RESOLUÇÃO (PASSO 1 E 2)

Gabarito: A Ilusão do Barplot

```
import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt

np.random.seed(42) # Trava o acaso
# Gerando 500 compras (A: média 120 / B: média 122) com muita variação
ticket_A = np.random.normal(loc=120, scale=35, size=500)
ticket_B = np.random.normal(loc=122, scale=40, size=500)

# Unificando no DataFrame
df = pd.DataFrame({
    'versao': ['A']*500 + ['B']*500,
    'ticket': np.concatenate([ticket_A, ticket_B])
})

# Passo 2: O Barplot
sns.barplot(data=df, x='versao', y='ticket')
plt.show()

# VISUAL: A barra B vai parecer discretamente mais alta na tela.
```

RESOLUÇÃO (PASSO 3)

Gabarito: A Sentença do SciPy

```
from scipy import stats

# Filtramos as arrays puras
array_A = df[df['versao'] == 'A']['ticket']
array_B = df[df['versao'] == 'B']['ticket']

# Injetamos na máquina
estatistica, p_valor = stats.ttest_ind(array_A, array_B)

print(f"P-Valor extraído: {p_valor:.4f}")
if p_valor < 0.05:
    print("A diferença é real. Dêem o bônus.")
else:
    print("É ruído (Sorte). A tela nova é inútil.")
```

Output do Console: P-Valor: 0.1384 ->É ruído. Tela inútil.

Tradução Executiva do PBL

- A Cegueira do Barplot: O gráfico de barras nos enganou. A barra do 'B' realmente estava mais alta porque a amostra do B tinha uma média matemática ligeiramente maior.
- O Peso da Dispersão: Nós colocamos propositalmente um desvio padrão enorme na hora de simular os dados (scale=35 e 40). O SciPy percebeu que as compras variavam muito.
- **O Veredito Final:** O P-Valor cravou quase 14% (0.1384). Como isso é muito superior aos 5% de tolerância da nossa régua (α), é estatisticamente estúpido aprovar o design em produção baseando-se nessa amostra. O Botão Laranja não aumenta receita.

Cenas do Próximo Capítulo

A Teia de Aranha (Correlação)

Hoje comparamos categorias discretas (Verde vs Laranja).

Na próxima aula, vamos cruzar as variáveis contínuas entre si usando o Gráfico de Dispersão (Scatterplot). Entraremos na matriz de Pearson e Covariância para responder à pergunta clássica: "O investimento em marketing causa diretamente o aumento do lucro, ou há outra variável escondida movendo as cordas?"