

DATA SCIENCE

A Teia de Aranha

Correlação, Covariância e Causalidade

Prof. Rafael Duarte

Recapitulando vs O Novo Desafio

Até Aqui (Grupos Isolados)

A avaliação consistia em estudar o comportamento de uma variável (Ex: Distribuição de salários) ou comparar categorias distintas através de Testes A/B (Ex: Interface Verde vs Laranja).

O Novo Desafio (Duas Contínuas)

Como analisar duas variáveis numéricas contínuas crescendo simultaneamente? (Ex: "Investimento em Marketing" vs "Vendas").

Como provar matematicamente que o movimento de uma puxa a outra?

O Paradoxo do Tubarão e do Sorvete

Em uma cidade litorânea, os dados revelam um padrão matemático perfeito: nas épocas do ano em que as vendas de sorvete disparam, os ataques de tubarão sobem na exata mesma proporção.

Conclusão baseada em dados: Sorvete atrai tubarão?

A REGRA DE OURO:
"Correlação NÃO implica Causalidade"

Correlações Espúrias (O Caos do Acaso)

Exemplo 1: Aquecimento Global

Os registros indicam que a temperatura média da Terra aumentou nos últimos séculos na mesma exata proporção em que o número de piratas marítimos diminuiu.

Exemplo 2: Nicolas Cage

A taxa de filmes lançados anualmente pelo ator Nicolas Cage possui uma curva perfeitamente sincronizada com o número de pessoas afogadas em piscinas nos EUA naquele ano.

A matemática acha padrões perfeitos até onde reina a pura coincidência amostral.

O Segredo da Variável Oculta

No caso real dos tubarões e sorvetes, o que causa a sincronia perfeita dos gráficos se um não interfere no outro?

A Terceira Força (Confounding Variable)

O Verão (Calor). O aumento da temperatura é o verdadeiro causador: ele induz o aumento do consumo de sorvete e induz o aumento de banhistas no mar (aumentando a exposição a tubarões).

O Raio-X Visual

O Gráfico de Dispersão (Scatterplot)

Lendo a Nuvem de Pontos


O Scatterplot mapeia cada registro como um único ponto. (Eixo X = Causa presumida | Eixo Y = Efeito presumido).

Positiva



X sobe, Y sobe.

Negativa



X sobe, Y desce.

Caótica



Zero padrão visual.

O Motor Matemático (Covariância)

A avaliação visual ("olhômetro") não sustenta relatórios corporativos. É necessário um indicador matemático exato.

A Lógica da Covariância:

- Avalia o cruzamento das distâncias de cada ponto até a média de X e a média de Y .
- Identifica se a dispersão ocorre em quadrantes concordantes ou discordantes.

A Matemática da Covariância

$$Cov(X, Y) = \frac{\sum (x_i - \bar{x}) \cdot (y_i - \bar{y})}{n - 1}$$

Multiplicação Concordante

Se X está acima da média e Y também (+ com +), ou ambos estão abaixo (– com –), a multiplicação resulta em positivo.

Multiplicação Discordante

Se caminham em direções opostas em relação às suas médias (+ com –), o resultado final puxa para o negativo.

O Problema da Covariância (A Escala)

O Teto Infinito

A fórmula da covariância pode resultar em 50, 5.000 ou 1.000.000. O resultado absoluto não tem limite padronizado.

O Fator "Unidade de Medida"

Se avaliarmos "Peso vs Altura" utilizando Metros e Quilos, obtemos um valor X. Se utilizarmos os mesmos dados, mas em Centímetros e Gramas, a covariância escala para os milhões. Não serve para comparações universais.

A Solução: Normalização

Para padronizar esse número globalmente e anular as unidades de medida (metros, dólares, reais, gramas), aplica-se a técnica matemática de Normalização.

A Covariância bruta é dividida pela variabilidade natural de cada eixo (Os Desvios Padrões de X e Y).

Correlação de Pearson (r)

$$r = \frac{Cov(X, Y)}{s_x \cdot s_y}$$

A divisão isola o comportamento conjunto da influência das escalas originais, criando um indicador métrico puro, independente da ordem de grandeza dos dados.

O Limite Mágico de Pearson

$$-1 \leq r \leq +1$$

-1

Correlação Negativa
Perfeita
(Inversamente
proporcional).

0

Nenhuma relação
linear detectada no
plano.

+1

Correlação Positiva
Perfeita
(Diretamente
proporcional).

O Espectro de Pearson (Guia de Bolso)

Coeficiente ($ r $)	Interpretação para o Negócio
0.7 a 1.0	Muito Forte. Indício robusto para criar regras preditivas seguras.
0.4 a 0.6	Moderada. Tendência existente, mas exige apoio de variáveis extras.
0.0 a 0.3	Fraca/Inútil. Desprezível para tomada de decisão confiável isolada.

O Ponto Cego de Pearson

A Premissa Linear

O coeficiente de Pearson rastreia rigorosamente a existência de linhas retas (taxas constantes de crescimento).

O Cenário Curvo

Se o fenômeno crescer de forma exponencial (uma curva acentuada, como a propagação viral), o Pearson tentará forçar uma reta no gráfico, falhará e indicará uma correlação artificialmente fraca.

A Solução de Spearman

A Avaliação por Ranking (Posição)

O algoritmo de Spearman soluciona o ponto cego alterando a regra do jogo: ele ignora a magnitude absoluta do número e foca apenas no "Pódio".

Se a variável A subir de posição (1º, 2º, 3º), a variável B também subiu de posição na mesma ordem? Se a resposta for sim, a relação é perfeita (não importa a velocidade da curva).

Pearson vs Spearman (Comparativo)

Pearson

- Busca Proporcionalidade Linear (Retas).
- Utiliza valores originais da base.
- Vulnerável a Outliers.

Spearman

- Busca Monotonicidade (Se um sobe, o outro não cai).
- Utiliza Ordens/Rankings.
- Resistente a Outliers e ideal para curvas.

Visão Sistêmica

O Problema das Múltiplas Variáveis no Data Warehouse

A Matriz de Correlação

No mundo real, as bases possuem 50, 100 ou milhares de colunas. Aplicar o Scatterplot manualmente (X vs Y) para cada par de variáveis é inviável.

A Solução Tabular ($N \times N$)

O código computacional processa todas as variáveis numéricas contra elas mesmas em uma única execução matricial. Nota: A diagonal principal será sempre 1.0 (Variável comparada contra si mesma é linearmente perfeita).

O Mapa de Calor (Heatmap)

A Sobrecarga Cognitiva

Apresentar uma tabela gigantesca repleta de decimais (0.41, -0.85, 0.02) inviabiliza a leitura executiva.

O Mapeamento Visual

A biblioteca substitui a carga numérica por pigmentação. Cores Quentes/Fortes representam laços densos de correlação. Cores Frias/Bejes representam ausência de padrão (acaso).

Dinâmica da Oficina Prática PBL

Laboratório: Startup Imobiliária

- Os exercícios seguirão a progressão do Colab (Acessem a Parte 2 do arquivo que receberam).
- O Dataset `California Housing` expõe atributos estruturais de residências. O objetivo principal é guiar as políticas de precificação.
- A Entrega: Executem os comandos, preencham a interpretação solicitada nos comentários de cada desafio e enviem no Blackboard (Tarefa Aula 06).



Momento da Chamada

INTERVALO

Pausa técnica. Na sequência, retornaremos aos Notebooks.

O Desafio Imobiliário

O CEO da Startup requisitou o cruzamento de todas as colunas de métricas das propriedades cadastradas na base histórica.

A Pergunta Central:

"Dentre todas as variáveis disponíveis, qual característica do imóvel possui o maior poder estatístico de influenciar positivamente ou negativamente o seu Preço de Venda?"

A Matriz de Correlação

A base contém múltiplas colunas de dados numéricos (Renda, Idade, Quartos, etc).

Instrução:

Aplique a função base do Pandas para gerar a matriz bidimensional de Pearson. Salve o resultado e exiba isoladamente a coluna respectiva ao alvo ('Preco'), ordenando os valores em ordem decrescente para facilitar a leitura.

RESOLUÇÃO: DESAFIO 1

Gabarito da Matriz

O Mapa de Calor (Heatmap)

O vetor numérico exibido no terminal atende o Engenheiro, mas dificulta a interpretação macro da Diretoria.

Instrução:

Utilizando o módulo `seaborn`, converta a matriz quadrada gerada no passo anterior em um gráfico Heatmap bidimensional. Certifique-se de ativar o parâmetro que injeta os valores numéricos no interior de cada célula de cor.

RESOLUÇÃO: DESAFIO 2

Gabarito Visual do Heatmap

A Prova Visual (Scatterplot)

O índice principal obtido apontou que a 'Renda_Bairro' governa o aumento do 'Preço'. Um valor de $+0.68$ é moderado para muito forte.

Instrução:

Traga à tela a dispersão geométrica desses dois eixos usando um Gráfico de Dispersão. Coloque 'Renda_Bairro' no eixo das abscissas e 'Preço' nas ordenadas. Acrescente transparência ('alpha') para lidar com a densidade populacional dos pontos no gráfico.

RESOLUÇÃO: DESAFIO 3

Gabarito da Nuvem Bidimensional

A Filtragem do Ruído (Outliers)

O Limite Artificial do Sistema:

Detectamos que as casas de super luxo sofreram um truncamento sistêmico no teto exato de \$500.000, criando um Outlier massivo no gráfico de dispersão e ferindo a pureza do Pearson.

Instrução:

Aplique uma máscara booleana para ignorar/filtrar todos os registros de casas precificadas a \$500.000 ou superior. Recalcule o índice da Correlação de Pearson entre a Renda e o Preço nesse subset limpo e verifique a alteração da "força".

RESOLUÇÃO: DESAFIO 4

Gabarito: A Pureza Matemática

Cheat Sheet: O Arsenal da Aula

Comando Pandas/Seaborn	Execução Prática
<code>df.corr()</code>	Computa e gera a matriz global de Covariância normalizada via Pearson ($N \times N$).
<code>df.corr(method='spearman')</code>	Força o cálculo da matriz de hierarquia ordinal (ideal para crescimento curvo não linear).
<code>sns.heatmap(matriz, annot=True)</code>	Converte o quadro cartesiano de decimais em um mapa térmico colorido para rápida leitura sistêmica.
<code>sns.scatterplot(x='A', y='B')</code>	Renderiza a disposição em nuvem de coordenadas cruzando os vetores da variável A com B.

Cenas do Próximo Capítulo

A Transição: Predizendo o Futuro

Hoje avaliamos matematicamente que a Renda é o vetor que arrasta o Preço da casa.

Mas e se fornecermos ao sistema um bairro cuja Renda seja de R\$ 15.000... o nosso sistema computacional consegue determinar (prever) exatamente em qual faixa de valor o imóvel deve ser anunciado hoje?

Na próxima aula, daremos início ao Bloco II da disciplina. Mergulharemos na Regressão Linear para extrairmos previsões estruturais.