

DATA SCIENCE

O Salto Preditivo

Machine Learning e Regressão Linear Simples

Prof. Rafael Duarte

A Descoberta Anterior (Aula 06)

Na última aula, utilizando a base California Housing, o algoritmo de Pearson atestou matematicamente o óbvio:

A "Renda do Bairro" puxa o "Preço do Imóvel".

Coeficiente $r \approx +0.69$ (Correlação Positiva Forte).

A Limitação da Correlação

Um Indicador, Não uma Resposta

O Coeficiente de Correlação (Pearson) e o Scatterplot apenas confirmam a existência de uma relação.

A Pergunta de Negócio

Se um cliente informar que a Renda Média de um bairro recém-inaugurado é de U\$ 8.500... Qual será o preço exato da casa? O Pearson não consegue gerar esse número. Nós precisamos de uma equação.

O Salto Preditivo

Aprendizado de Máquina (Machine Learning)

A máquina observará todos os milhares de pontos (Renda vs Preço) do passado e tentará aprender a regra matemática estrutural que governa esse mercado.

Uma vez aprendida, a máquina transforma essa regra num "motor" capaz de receber dados inéditos e cuspir previsões absolutas.

O Aprendizado Supervisionado

O Professor (Você)

Nesta categoria de IA, você fornece à máquina não apenas as variáveis (Renda), mas também o gabarito histórico (Os preços pelos quais as casas foram realmente vendidas).

O Aluno (O Algoritmo)

A máquina treina exaustivamente tentando relacionar a Causa ao Efeito (Gabarito), ajustando seus parâmetros internos até que sua margem de erro seja mínima.

A Geometria da Previsão

Regressão Linear Simples

A Equação da Reta (Geometria Analítica)

A máquina tenta traçar uma reta única que atravessasse perfeitamente o centro da nuvem de pontos. Essa reta é governada pela equação universal:

$$\hat{y} = w_1x + w_0$$

- $\hat{y}$ = A nossa previsão (Preço estimado).
- x = A variável de entrada (Renda informada).
- w_1 = O Peso (Coeficiente Angular / Inclinação).
- w_0 = O Viés (Intercepto / Ponto de Partida).

O Peso / Inclinação (w_1)

A Alavanca

O w_1 dita a inclinação da reta. Ele responde à pergunta:
"Para cada 1 dólar a mais na Renda, o Preço da casa sobe quantos dólares?"

Exemplo

Se $w_1 = 5.0$, significa que um aumento de U 1.000 na Renda do Bairro eleva o preço da casa em U 5.000 matematicamente.

O Viés / Intercepto (w_0)


O Ponto de Ancoragem

O w_0 é o ponto onde a reta cruza o eixo Y. Ele responde à pergunta: "Se a renda do bairro for absolutamente ZERO, qual seria o preço base da casa?"

Necessidade Algorítmica

Mesmo que um bairro não tenha renda rastreada, a casa tem tijolo, telhado e terreno. O valor dela não é zero. O Viés serve para "ancorar" a equação no mundo real.

A Reta na Nuvem de Pontos



A linha azul representa a Previsão da IA ($\hat{y}$). As bolinhas representam a Realidade (Histórico). O ponto de toque no Eixo Y é o w_0 .

O Erro (Resíduo)

A Imperfeição

Nenhuma reta passa perfeitamente sobre todos os pontos. A distância vertical entre o ponto real (histórico) e a linha azul desenhada pela máquina é chamada de Erro ou Resíduo (e).

O Objetivo da Máquina

O aprendizado de máquina consiste em inclinar e levantar a reta (testando milhares de pesos w_1 e w_0) até encontrar a exata posição geométrica em que a soma total de todos os erros seja a menor possível.

Mínimos Quadrados (OLS)

O algoritmo matemático que busca essa reta perfeita é o Ordinary Least Squares (Mínimos Quadrados Ordinários).

Por que "Quadrados"?

Porque pontos que estão acima da reta geram erros positivos (+5.000), e pontos abaixo geram erros negativos (−5.000). Se o algoritmo apenas somasse, os erros se anulariam, indicando ilusoriamente um erro zero. O OLS eleva os erros ao quadrado para torná-los todos positivos antes de somá-los.

Demonstração: A Reta Manual

Do Quadro para o Código

Vamos ao Google Colab agora.

Iremos desenhar o Scatterplot e aplicar uma linha de regressão visual sobre a nuvem de Renda vs Preço antes de entrarmos no código avançado.

O Motor Preditivo

Introdução à biblioteca Scikit-Learn

Scikit-Learn (O Padrão da Indústria)

Nenhum engenheiro de dados calcula os Mínimos Quadrados na mão em produção. Nós utilizamos a biblioteca scikit-learn, o padrão global para Machine Learning tradicional em Python.

1. Instanciar

Criar a IA vazia.

2. Treinar (.fit)

Apresentar os dados.

3. Prever (.predict)

Gerar previsões inéditas.

A Exigência Algorítmica da Matriz 2D

Atenção: O erro mais comum do iniciante!

A variável de resposta (Y - Preço) pode ser uma lista simples (Vetor 1D). Porém, as variáveis independentes (X - Renda) que entram no treinamento DEVEM OBRIGATORIAMENTE ser empacotadas como uma Matriz Bidimensional (2D).

```
# ERRADO (Vetor 1D - Vai explodir o Scikit-Learn)
X = df['Renda_Bairro']

# CORRETO (Matriz 2D - Uso de duplo colchete)
X = df[['Renda_Bairro']]
```

1. Instanciando o Modelo

Trazendo a biblioteca para a memória e criando a "casca vazia" do nosso modelo linear.

```
from sklearn.linear_model import LinearRegression

# Criando a IA (Ainda não aprendeu nada)
modelo = LinearRegression()
```

2. O Treinamento (.fit)

É aqui que o algoritmo de Mínimos Quadrados trabalha bilhões de vezes por segundo inclinando a reta para achar os pesos perfeitos (w_1 e w_0).

```
# df[['Renda_Bairro']] é o X (A causa)
# df['Preco'] é o Y (O Gabarito)

modelo.fit(X, y)
```

Dura milissegundos. A máquina agora possui o "motor" treinado.

3. A Previsão Inédita (.predict)

Extraindo respostas. Informamos uma nova renda e exigimos que a equação preveja o preço de mercado daquele imóvel.

```
# Simulando a Renda de um bairro fictício (U$ 8.500)
# Lembrando: A entrada exige formato 2D!
renda_nova = [[8.5]]

# Prevendo o valor
preco_previsto = modelo.predict(renda_nova)

print(preco_previsto)
```

Avaliação

Como saber se a nossa IA é uma fraude?

MAE (Erro Absoluto Médio)

A Lógica Simples

O MAE (Mean Absolute Error) calcula a diferença entre o Preço Real e o Preço que a sua IA tentou prever. Ele retira o sinal negativo (Módulo) e tira a média geral de todos os erros do banco de dados.

O Significado

Se o MAE for de U\$ 45.000, significa que as previsões da nossa IA estão, em média, "errando o alvo" por 45 mil dólares para cima ou para baixo.

MSE e RMSE (As Métricas Oficiais)

MSE (Erro Quadrático Médio)

Eleva o erro ao quadrado. Pune severamente os "erros gigantes". O problema é que o resultado financeiro fica na casa dos bilhões (Dólares ao Quadrado). Ilegível para negócios.

RMSE (Raiz do Erro Quadrático Médio)

Tiramos a Raiz do MSE para voltar aos dólares normais. É a métrica mais respeitada na avaliação de regressões globalmente. Ele representa o "Erro Padrão" da nossa previsão.

R^2 (Coeficiente de Determinação)

A Taxa de Sucesso

O RMSE é absoluto (U

50mil é ruim para uma casa de 100mil, mas é excelente para uma mansão de 1 milhão).

R^2 é um número relativo que vai de 0 a 1 (0% a 100%).

O Significado

Se $R^2 = 0.47$, significa que a Renda do Bairro consegue

explicar matematicamente 47% das variações nos Preços. O resto do preço (53%) é causado por variáveis que estão fora do nosso modelo (Tamanho, Idade, Quartos, Piscina).

Dinâmica da Oficina Prática PBL

O Primeiro Modelo Produtivo

- Retornem ao Colab (Mesmo arquivo). Desçam para a Seção "Parte 2: Scikit-Learn".
- A Entrega: Cumpram os 4 desafios (Formatar a Matriz, Treinar o Fit, Extrair a Equação e Avaliar as Métricas R2/RMSE).
- Subam a versão final consolidada do Notebook no Blackboard para validação.



Momento da Chamada

INTERVALO

Descansem as máquinas. O treinamento da Inteligência Artificial vai começar.

A Arquitetura das Matrizes (X e Y)

Isolando Fatores:

O Scikit-Learn não aceita a tabela inteira do Pandas de uma vez. O algoritmo precisa que o Alvo (Preço) e a Causa (Renda) sejam rigorosamente segregados.

Missão: Separe o dataset em y (série 1D) e X (matriz 2D).

O Motor (Instanciar e Treinar)

A Caixa Preta:

É a hora de submeter os dados separados ao processo de Mínimos Quadrados Ordinários.

Missão: Importe o LinearRegression, instancie o modelo e treine passando o X e o y. Depois gere as previsões para toda a base na variável previsoes.

Raio-X: Extraíndo a Equação

A Caixa Transparente:

O modelo treinou, mas o que ele aprendeu? Qual foi a angulação exata e o intercepto (w_1 e w_0) que ele determinou como perfeitos para a Califórnia?

Missão: Imprima os atributos `coef_` e `intercept_`. Interprete nos comentários quanto em dólares o imóvel sobe caso a renda suba 1.0 (Mil dólares).

As Métricas da Verdade (RMSE e R^2)

O Julgamento:

O CEO não quer saber de matrizes, ele pergunta: "Qual a margem de erro financeiro da nossa IA em dólares?" e "Com qual taxa de segurança esse modelo governa as variações?".

Missão Final: Importe o R^2 Score e o Mean Squared Error. Calcule a raiz quadrada (RMSE) e escreva um parágrafo para a Diretoria atestando a qualidade e a margem de erro da nossa IA.

Cheat Sheet: O Arsenal Preditivo

Comando Scikit-Learn

Execução Prática

```
modelo = LinearRegression()
```

Instancia o motor vazio sem pesos configurados.

```
modelo.fit(X, y)
```

Roda o algoritmo de Mínimos Quadrados e encontra w_1 e w_0 . X deve ser Matriz 2D.

```
y_pred = modelo.predict(X_new)
```

Gera as respostas financeiras com base nas regras aprendidas.

```
mean_squared_error(..., squared=False)
```

Gera o RMSE. Se esquecer o False, ele retorna o MSE comutado em Bilhões ($R\$$ ao quadrado).

Cenas do Próximo Capítulo

A Ilusão do Memorizador (Train/Test Split)

Hoje o nosso R^2 cravou 47.3% e o nosso erro foi de U\$ 83 mil. Mas cometemos o maior "crime" do Machine Learning: Nós avaliamos a máquina utilizando as exatas mesmas casas que ela usou para estudar! (É como dar a prova final com as respostas impressas para o aluno ler um dia antes).

Será que se testarmos a máquina com casas que ela nunca viu na vida o erro de U\$ 83 mil vai se manter, ou o modelo vai derreter em produção?

Na próxima semana: Regressão Múltipla, Train/Test Split (Divisão de Treino e Teste) e Generalização!